

## Pre-tokenisation of a Telugu sentence

cl100k pattern ( $\backslash p\{L\}+$ )  $\rightarrow$  15 pieces

హ ా య్ , న నే న ం ప ర క్ష ం శి స త్త ం న ం .

o200k pattern ( $+\backslash p\{M\}$ )  $\rightarrow$  5 pieces

హాయ్ , నేను పరీక్షిస్తున్నాను .